UNIVERSIDADE LaSalle

Estrutura de Dados
Estrutura de Dados I

Elgio Schlemer
elgio.schlemer@unilasalle.edu.br

Compressão de dados

- Processo matemático para representar uma informação em uma forma mais econômica.
- Termos:
  - Compressor ou Encoder
  - Decompressor ou Decoder
  - Codec = compressor ou decompressor

Compressão de dados

- compressão não destrutiva:
  - ao descomprimir os dados recupera-se exatamente o original
  - Exemplos: ZIP, GZIP, RAR, BZIP2 são não destrutivos
- compressão de dados destrutiva:
  - parte dos dados é destruída
  - ou ignorada durante a etapa de compactação
  - quando se for descompactar, não se recupera a informação original.
  - PERDE-SE, DESTRÓI-SE parte da informação.
  - Exemplo: GIF, JPEG, MP3, MP4, …

Compressão de dados

- compactação é baseada na redundância
  - dados repetidos podem ser representados uma única vez
- Tipos de redundância:
  - Alfabética
    - símbolos que repetem
    - Exemplo: a letra 'A' em um texto em português
  - Contextual
    - conjunto de símbolos que repetem
    - Exemplo: while em um código fonte

Categorias de métodos de compressão

- RLE (Run Lengh Encoding)
- Métodos estatísticos
- LZ: métodos baseados em dicionário

RLE (Run Lengh Encoding)

- se informação i apareceu n vezes consecutivas
  - representa-se ela como ni
  - Exemplo:

AAAAAA Minha matricula é 0000000529	A6 6Minha matricula é 07529
41 caracteres de tamanho	28 caracteres de tamanho (68% do original)

- Problema do RLE: número é ele mesmo ou se a repetição do anterior?
  - é o 0 que se repete 7 vezes, ou é o 0 normal seguido do 7?
- Soluções:
  - Escolher símbolo não pertencente ao conjunto de dados para indicar uma repetição
  - Um padrão de repetição, por exemplo, letra 3 vezes é repetição SEMPRE

RLE

Original	AAAAAAAA Minha matricula e 0000000529 BBBBBBBBBB TTTTTTTTTTTT 9876666666666333	84 cars
RLE usando # como marcador (10 e 12 é decimal, um car)	#A8# 6Minha matricula e #07529 # 2#B10 #T12 987#610#33	50 cars
RLE usando 3 vezes como marcador (10 é um byte. Inteiro 10. 12 também)	AAA8 6Minha matricula e 0007529 BBB10 TTT12 98766610333 3	56 cars

RLE

- Exemplos de uso
  - PCX
  - BMP
  - TIFF
  - PDF

Métodos estatísticos

- Símbolos que mais se repetem
  - são representados com informação menor
- Exemplo:
  - o 'A' aparece muito mais em um texto do que o 'W'
  - mas ambos usam 8 bits para representar
  - E se o 'A' fosse representado apenas por 2 bits?
  - mesmo que o 'W' precisasse de 20

Algoritmo de Huffmann

- Usa uma árvore estatística para realizar a compressão
- Construção da árvore:
  - contabilizar a ocorrência dos símbolos
  - ordenar inversamente pela frequência
  - Exemplo:

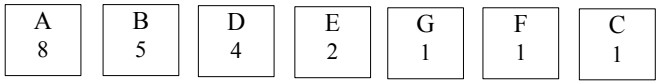

Algoritmo de Huffmann

- Agrupar os símbolos menos frequentes em um raiz

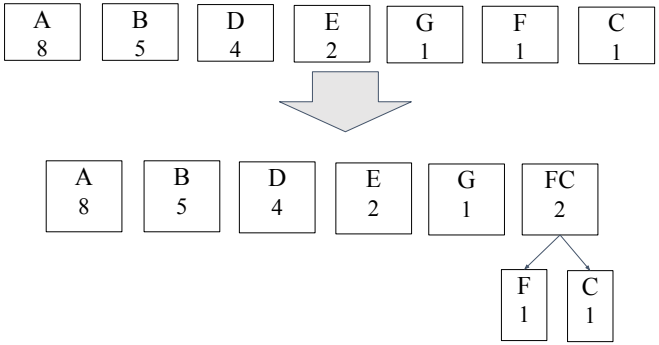

Algoritmo de Huffmann

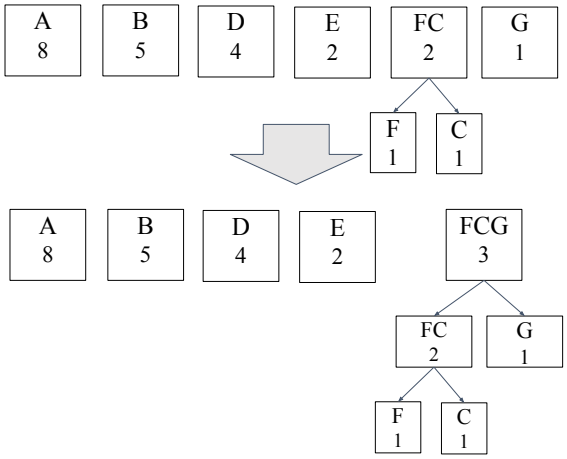

Algoritmo de Huffmann

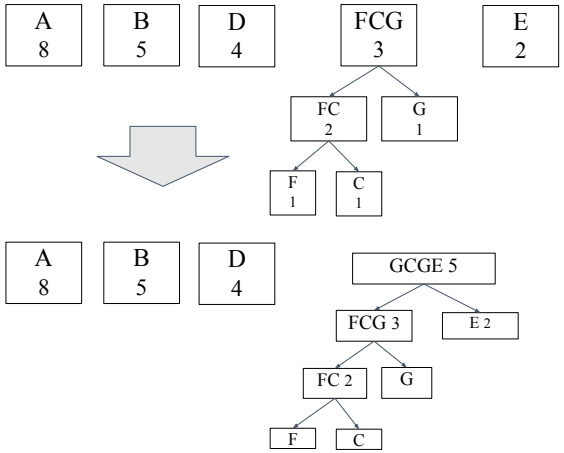

Algoritmo de Huffmann

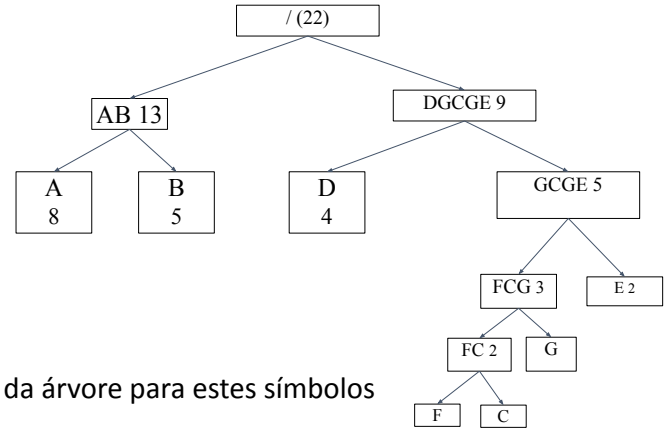

Fim da árvore para estes símbolos

Algoritmo de Huffmann

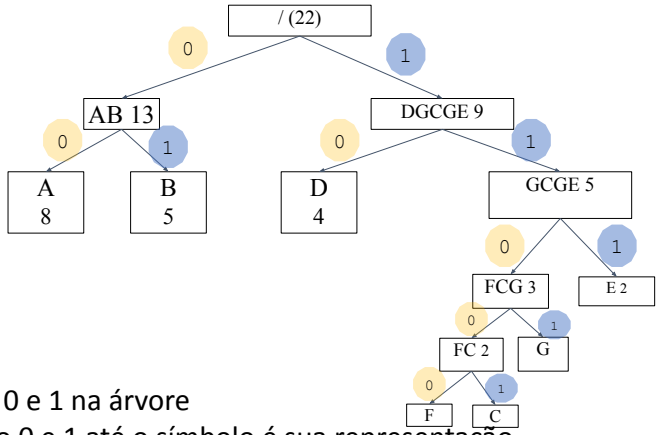

Coloca-se 0 e 1 na árvore
O caminho 0 e 1 até o símbolo é sua representação

Algoritmo de Huffmann

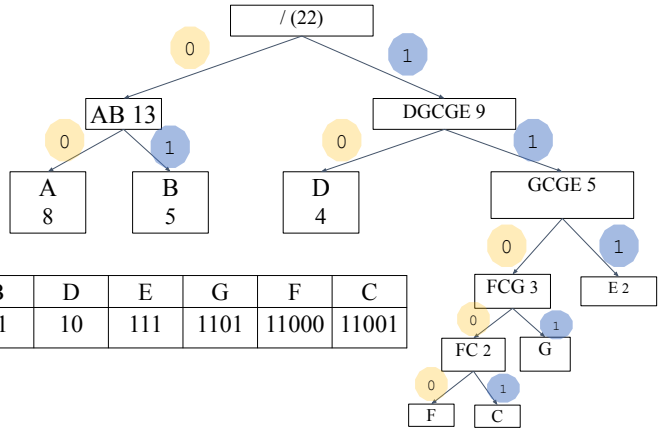

A	B	D	E	G	F	C
00	01	10	111	1101	11000	11001

Compressão de dados

Compressão de dados

Compressão de dados

Compressão de dados

Até a próxima aula, dia 30